

Concepto Introductorios y Fundamentos del Big Data

Presentación del Curso

Presentación

- <https://www.youtube.com/watch?v=l8Wny1ZEG8I>

Horas de asesoría

- Lunes 5pm-6pm
- Martes 4pm-5pm
- Miércoles 5pm-6pm
- Jueves 6pm-7pm (Solo Virtual)

Lugar: Laboratorio ITLAB (piso 2 pabellón I2)

Zoom (*): <https://ulima-edu-pe.zoom.us/j/95728854972?pwd=dGtQU2JhSUh4WmhMMHI4Ykt1cnZEUT09>

(*) Se dará preferencia a las visitas presenciales.

Normas

- Se tomará lista a 20 minutos de iniciada la clase y también al final.
- No estar en alguna lista invalida su asistencia.
- No se puede justificar inasistencias, a no ser por lo siguiente:
 - Faltar más de 1 semana (con secretaría académica)
 - Eventos deportivos acreditados por secretaría académica.
 - Reunión de delegados (de darse el caso).
- En caso de evaluaciones, para toma de rezagados:
 - Justificar con evidencias la inasistencia en las siguientes 24 horas de realizada la evaluación.

Código de Ética ULima

La Universidad de Lima fomenta la innovación, el desarrollo científico y el pensamiento crítico de su comunidad. Asimismo, promueve la protección y el respeto de las obras que son producto del esfuerzo académico en todas sus manifestaciones. En tal sentido, se considera como plagio cualquier acción que utilice el trabajo de otra persona o el resultado del empleo de inteligencia artificial como propio, sin permiso o sin mencionar la fuente. Esta acción constituye una transgresión a los derechos de autor y a las normas éticas que sustentan el trabajo académico. Asimismo, se considera plagio en las evaluaciones académicas utilizar o acceder a medios o información distintos a los permitidos para el desarrollo de la evaluación.

Evaluación

N.º	Semana	Tipo de evaluación	Peso	Calificación	Logro
1	5	Examen escrito 1 (EE)	25%	100% individual	L1, L2
2	9	Examen escrito 2 (EE)	25%	100% individual	L3, L4
3	13	Examen escrito 3 (EE)	25%	100% individual	L4, L5
4	15	Trabajo de producción	25%	100% grupal	L3, L4, L5

¿Por qué un curso de Analítica con Big Data?

Experimentación => Producción

- Diferentes enfoques: **Data scientist** enfocado en investigación y entrenamiento de modelos, **Data Engineer** se encarga de la industrialización de estos modelos.



¿Por qué un curso de Analítica con Big Data?

Especialización en Arquitecturas Modernas

- La IA no son solamente chatbots.
- Tenemos:
 - **Sistemas RAG:** El AI Engineer diseña el flujo donde la IA consulta manuales, SQLs o documentos privados para dar respuestas sin "alucinaciones".
 - **Agentes autónomos:** Desarrollan sistemas capaces de ejecutar tareas (ej. "reserva este vuelo y actualiza el presupuesto en SAP") de forma independiente.



¿Por qué un curso de Analítica con Big Data?

Retorno de inversión en empresas

- Las organizaciones actuales ya no invierten en IA por "moda", sino por resultados:
 - Optimización de Costos
 - Mantenimiento y Monitoreo (LLMOps)

Big Data

¿Qué es Big Data?

- No solo se refiere a “muchos datos”.
- Paradigma que describe activos de información de una gran magnitud, que requieren formas específicas de procesamiento y métodos analíticos que permitan la toma de decisiones, descubrimientos de patrones y optimización de procesos.


Múltiplos de bytes			
Sistema Internacional (decimal)		ISO/IEC 80000-13 (binario)	
Múltiplo (símbolo)	SI	Múltiplo (símbolo)	ISO/IEC
kilobyte (kB)	10^3	kibibyte (KiB)	2^{10}
megabyte (MB)	10^6	mebibyte (MiB)	2^{20}
gigabyte (GB)	10^9	gibibyte (GiB)	2^{30}
terabyte (TB)	10^{12}	tebibyte (TiB)	2^{40}
petabyte (PB)	10^{15}	pebibyte (PiB)	2^{50}
exabyte (EB)	10^{18}	exbibyte (EiB)	2^{60}
zettabyte (ZB)	10^{21}	zebibyte (ZiB)	2^{70}
yottabyte (YB)	10^{24}	yobibyte (YiB)	2^{80}

Objetivos

¿Qué quieres conseguir?

- Analizar grandes cantidades de datos que requieren ser procesados.
- Analizar menos datos, pero procesándolos en tiempo real.
- Analizar datos que tengan un formato difícil y no estructurado ni predecible (audios, videos).
- Analizar datos cuyas fuentes no sean totalmente confiables

Proceso del Big Data



Datos

Diferencia con *Data Analytics*

- Data Analytics: Es el proceso de extraer conclusiones de los datos.
- Big Data: Infraestructura que soporta la gestión de los datos.

Actividad 1

Aplicación del Big Data en la industria

- En grupos y utilizando IA, responder las siguientes preguntas y subirlas al foro llamado Actividad 1.
- ¿Cómo se aplica Big Data en el sector en el que labora o laboró? En caso ninguno del grupo trabaja o trabajó, puede elegir cualquier sector productivo peruano (<https://www.brysonhillsperu.com/2024/08/01/cuales-son-los-5-sectores-productivos/>)

Vs

Las 4 Vs

- Nos permiten describir la naturales de los datos en procesos Big Data.
- Son:
 - Volumen
 - Velocidad
 - Variedad
 - Veracidad

Volumen

- Se refiere a la magnitud física de los datos (Laney, 2001). Ya no hablamos de Gigabytes, sino de escalas que superan la capacidad de almacenamiento y procesamiento de sistemas tradicionales (Petabytes, Exabytes).
- Existe una cantidad masiva de datos generados cada segundo, por lo que el desafío es la forma de almacenamiento y procesamiento en un solo servidor o en una base de datos relacional.
- Ejm:
 - Una cadena de supermercados global. Cada transacción en cada caja, en cada país, genera un registro. Al año, esto suma miles de millones de filas que una hoja de Excel o un SQL tradicional no podrían abrir.
 - Los aviones modernos de Boeing generan aproximadamente 20 Terabytes de datos por motor cada hora de vuelo. Multiplicado por miles de vuelos diarios, el volumen es masivo.

Velocidad

- Es la rapidez con la que se generan, capturan y procesan los datos. No se trata solo de qué tan rápido llegan, sino de qué tan rápido debemos reaccionar a ellos.
- En muchos casos, los datos pierden su valor si no se analizan en "tiempo real" o "casi real".
- Ejm:
 - Los sistemas de detección de fraude con tarjetas de crédito. El banco tiene milisegundos para analizar una transacción y decidir si la bloquea antes de que se complete el pago.
 - Los sensores de un auto autónomo. Si el sensor detecta un obstáculo, la analítica debe procesar ese dato en milisegundos para frenar. Si el análisis tarda 10 segundos, el dato ya no sirve.

Variedad

- Se refiere a la heterogeneidad de las fuentes de datos (textos, audios, videos, logs de servidores, datos de sensores GPS, etc).
- El Big Data integra datos de diversas estructuras que deben convivir en un mismo ecosistema.
- Ejm:
 - Una empresa de retail analiza datos de ventas (Estructurados), comentarios en redes sociales (No estructurados) y grabaciones de cámaras de seguridad en tiendas (No estructurados).
 - El perfil de un cliente en una operadora telefónica. Tienen sus datos de contrato (estructurado), las grabaciones de sus llamadas a soporte (audio/no estructurado) y sus publicaciones en Twitter quejándose del servicio (texto/no estructurado).

Veracidad

- Incertidumbre de los datos con los que se trabajan. Pueden tener sesgos, ruido, errores o estar incompletos.
- Ejm:
 - En el análisis de redes sociales, existen cuentas falsas (bots) o errores gramaticales que pueden distorsionar el análisis de sentimiento si no se filtran adecuadamente.
 - Un análisis de mercado basado en GPS. Si los datos de ubicación tienen un margen de error de 500 metros, el análisis de "tráfico en tienda" será erróneo. Los alumnos deben aprender que antes de analizar, hay que limpiar.

¿Y el Valor?

- Se le considera la 5ta y más importante V. De nada sirve tener un sistema de Big Data si no genera valor al negocio.
- El valor es **extrínseco** al dato y depende del análisis.
- Ejm: Beneficio vs Costo en Almacenamiento y Procesamiento.

Pregunta

- ¿En qué contextos aplicaría un sistema de Big Data en el contexto de la Universidad de Lima?
- Tomar en cuenta las 5 Vs explicadas anteriormente.

Fuentes de datos

Fuentes de datos

- Podemos agruparlos por su naturaleza o por cómo se originan estos datos.

Máquinas

Por cómo se originan

- Las máquinas con sensores generan gran cantidad de datos.
- Obtienen y analizan datos de forma autónoma.
- Ejemplos:
 - Smartphone: Información de geolocalización
 - Aviones: Aproximadamente 500 GB generados por vuelo.
 - Internet de las Cosas (IoT): Relojes (data biométrica).

Personas

Por cómo se originan

- Datos obtenidos de redes sociales
- Datos biométricos
- La mayoría de los datos son no estructurados.



Organizaciones

Por cómo se originan

- Cualquier evento o transacción puede ser almacenado.
- Ejemplos:
 - Transacciones comerciales
 - Tarjetas de crédito
 - Historiales

Estructurados

- Datos que tienen una estructura conocida y predefinida.
- Ejemplos:
 - Bases de datos relacionales (tablas, columnas filas, relaciones)
 - Datos con estructura fija (protobuf, JSON, GraphQL, WSDL)

Semi-Estructurados


- Datos que tienen una estructura flexible.
- Ejemplos:
 - JSON, XML sin WSDL, bases de datos NO SQL.

No Estructurados

- Datos que no tienen alguna estructura.
- Ejemplos:
 - Texto, imágenes, audio, video.

Proceso del Big Data

Proceso del Big Data



Adquisición de datos


- Los datos se encuentran almacenados en diversos lugares:
 - Bases de datos relaciones o NO SQL
 - Archivos de texto
 - Datos remotos
- Técnicas de recolección:
 - SQL, colas, consultas, etc.
 - PubSub

Herramientas:


Bases de Datos, Hadoop

Preparación de los datos

- Exploración inicial de los datos
- Limpieza de los datos
 - Remover duplicados y datos con valores faltantes.
 - Eliminar ruido, generar estimaciones para valores no válidos.
- Transformación de la data
 - Reducción de la dimensionalidad
 - Feature engineering



Eliminación de ruido



Reducción de dimensionalidad

Procesamiento y análisis

- Análisis descriptivo
 - Agrupamiento
 - Analítica de grafos
 - Análisis de asociación
- Análisis predictivo
 - Regresión y Clasificación
- Modelamiento
 - Seleccionar la técnica
 - Construir el modelo
 - Validar el modelo

Herramienta:

Spark

Visualización

- Presentación de resultados
- Herramientas:
 - Python, R, Tableau, etc.

Utilización

- En base a los resultados, tomar acciones o medidas.
- Evaluación constante de los resultados para su mejora.