

Infraestructura para datos

Data Warehouses y Data Lakes

¿Qué es un Data Warehouse (DWH)?

"Un repositorio central de datos integrados, orientado al análisis histórico y la toma de decisiones, provenientes de múltiples fuentes operacionales."

W.H. Inmon (1992)



Dos enfoques arquitectónicos

Data Warehouse

W.H. Inmon — Top-Down

"Enterprise Data Warehouse"

- Diseño centralizado (3NF)
- DWH corporativo único
- Data Marts derivados del DWH
- Mayor consistencia de datos
- Implementación más larga
- Más costoso al inicio

VS



Ralph Kimball — Bottom-Up

"Dimensional Modeling"

- Diseño dimensional (esquemas estrella)
- Data Marts independientes
- Se integran en un Bus Architecture
- Entrega incremental más rápida
- Menor costo inicial
- Riesgo de inconsistencias


Top Down vs Bottom Up

Ejemplo




Esquemas relacionales

Modelado dimensional




- Estrella: Consultas más rápidas, menos JOINS pero mayor redundancia de datos.
- Copo de nieve: Datos normalizados, menos redundancia, mayor complejidad en queries.

Ejemplo



Estrella



Copo de nieve

Actividad 1

Modelado dimensional para matrícula

- Realizar el modelado dimensional que permita análisis del sistema de matrícula para la toma de decisiones. Ustedes debe de decidir las entidades y sus atributos que formarán parte del datamart (facts, dimensiones).

Data Lake

Almacenamiento sin esquema previo

Repositorio centralizado que permite almacenar cualquier tipo de datos en su formato nativo (estructurados, semiestructurados y no estructurados), a cualquier escala.



Data Lakehouse

- Paradigma moderno (popularizado por Databricks y Snowflake).
- Implementa la estructura y gobernanza de un DWH sobre la flexibilidad y bajo costo de un Data Lake.
- Es un Data Lake pero con una capa de metadatos:
 - Log para nuevos datos
 - Verificación de esquemas. Puede rechazar o actualizar esquemas.
 - Puede guardar históricos de archivos.

Comparativa

Característica	Data Warehouse	Data Lake	Data Lakehouse
Tipo de datos	Estructurados	Todos los tipos	Todos los tipos
Esquema	Schema-on-write	Schema-on-read	Schema-on-read
Costo de almac.	Alto	Bajo	Bajo-Medio
Calidad de datos	Alta (ETL previo)	Variable	Alta (Delta/Iceberg)
Casos de uso	BI, reportes SQL	ML, exploración	BI + ML + streaming
Ejemplos	Snowflake, Redshift	S3, HDFS, ADLS	Databricks, Delta Lake

Actividad 2 (guiada)

- Construcción de data lakehouse.

Procesamiento en Batch y En Stream

Procesamiento batch

Por lotes

Procesa grandes volúmenes de datos recolectados durante un período de tiempo, ejecutando el trabajo completo de una sola vez, sin interacción continua del usuario.



Herramientas principales

- Apache Hadoop / MapReduce
- Apache Spark (batch)
- Apache Hive
- Google BigQuery
- AWS EMR
- Apache Airflow (orquestración)

Procesamiento de Streams

Tiempo real

Procesa cada evento (o micro-batch) en cuanto llega, produciendo resultados continuos con latencia de milisegundos a segundos.

Evento	Unidad mínima de dato con marca temporal (timestamp)
Ventana (Window)	Tumbling, sliding, session — agrupa eventos por tiempo
Exactamente una vez	Garantía de procesamiento sin duplicados (exactly-once)
Backpressure	Control de flujo cuando el consumidor es más lento que el productor

Apache Kafka Streams

Apache Flink

Spark Structured Streaming

Apache Storm

Batch vs Stream: Comparativa

¿Cuándo usar cada uno?

Dimensión	Batch Processing	Stream Processing
Latencia	Alta (minutos-horas)	Baja (ms-segundos)
Throughput	Muy alto	Moderado-alto
Complejidad	Baja-Media	Alta
Costo	Bajo (recursos puntuales)	Medio-Alto (infra continua)
Caso de uso ideal	ETL nocturno, ML training, reportes	Detección fraude, alertas, dashboards live
Ejemplos reales	Facturación mensual, recomendaciones offline	Pagos en tiempo real, telemetría IoT