

Hadoop

Semana 4

Introducción a Hadoop

Hitos históricos

- - 2003 : Google publica el paper del *Google File System (GFS)*
- - 2004 : Google publica el paper de *MapReduce*
- - 2006 : Yahoo! separa el componente de Nutch: nace **Hadoop**
- - 2008 : Apache Software Foundation adopta Hadoop como proyecto top-level

Filosofía central

"Move the computation to the data, not the data to the computation"

- En lugar de mover petabytes por la red, Hadoop envía el código de procesamiento a los nodos donde ya residen los datos.


Problemática

¿Por qué las RDBMS tradicionales no escalan?

- Escalado **vertical** (hardware más potente) → costo prohibitivo y límites físicos
- Hadoop propone escalado **horizontal**: añadir nodos commodity de bajo costo

Arquitectura Hadoop

- **Hadoop Common:** Utilidades y librerías compartidas por todos los demás módulos del framework.
- **HDFS:** *Hadoop Distributed File System* — capa de almacenamiento distribuido y tolerante a fallos.
- **YARN:** *Yet Another Resource Negotiator* — gestión de recursos del clúster y planificación de trabajos.
- **MapReduce:** Modelo de programación para procesamiento paralelo de datos a gran escala.



Hadoop fue diseñado para correr sobre hardware commodity asumiendo que los fallos de nodos son la norma, no la excepción. La tolerancia a fallos es gestionada a nivel de software.

HDFS

Arquitectura de HDFS

- HDFS sigue una arquitectura ****maestro-esclavo**** con tres componentes principales:

NameNode (maestro)

- Almacena el namespace del sistema de archivos (metadatos: nombres, permisos, estructura de directorios)
- Registra el mapeo: qué bloques componen cada archivo y en qué DataNodes residen.
- **No almacena datos reales**, es el "índice" del sistema de archivos

DataNode (esclavos)

- Almacenan los bloques de datos en disco
- Envían *heartbeats* periódicos al NameNode para señalar que están activos
- Sirven las operaciones de lectura y escritura solicitadas por los clientes.

Secondary NameNode

- **No es un failover** del NameNode (nombre engañoso)
- Realiza *checkpoints* periódicos del namespace para reducir el tiempo de arranque del NameNode

Bloques en HDFS

- Tamaño por defecto: **128 MB** (configurable; bloques grandes reducen el overhead de metadatos)
- Un archivo grande se divide en múltiples bloques distribuidos entre los DataNodes del clúster
- Permite procesar bloques en paralelo en los nodos donde residen

Factor de Replicación

- Por defecto: **3 réplicas** por cada bloque
- Configurable en ``hdfs-site.xml`` mediante la propiedad ``dfs.replication``
- Las réplicas se distribuyen estratégicamente en distintos nodos y racks

Tolerancia a fallos

- Si un DataNode deja de enviar *heartbeats*, el NameNode lo marca como caído
- El framework **re-replica automáticamente** los bloques afectados para restaurar el factor de replicación

Comandos Básicos de HDFS

Listar archivos y directorios

```
hdfs dfs -ls /user/hadoop/
```

Crear un directorio en HDFS

```
hdfs dfs -mkdir /user/hadoop/datos
```

Subir archivo desde el sistema local a HDFS

```
hdfs dfs -put archivo_local.txt /user/hadoop/datos/
```

Descargar archivo de HDFS al sistema local

```
hdfs dfs -get /user/hadoop/datos/archivo.txt ./local/
```

Ver el contenido de un archivo directamente

```
hdfs dfs -cat /user/hadoop/datos/archivo.txt
```

Comandos Básicos de HDFS

Continuación

```
# Eliminar un archivo (usar -rm -r para directorios)
hdfs dfs -rm /user/hadoop/datos/archivo.txt
```

```
# Copiar archivo dentro de HDFS
hdfs dfs -cp /origen/archivo.txt /destino/
```

```
# Mover archivo dentro de HDFS
hdfs dfs -mv /origen/archivo.txt /destino/
```

Interfaz Web del NameNode

- El NameNode expone una ****UI Web**** para monitoreo y exploración del sistema de archivos.
- Funcionalidades principales:
 - Explorar el árbol de directorios y archivos de HDFS
 - Monitorear DataNodes: activos, inactivos y en decommission
 - Ver estadísticas de capacidad: espacio total, usado y libre
 - Consultar el estado de bloques bajo-replicados
 - Acceder a logs del NameNode

Goggle Cloud Storage como alternativa

En entornos cloud, **Google Cloud Storage (GCS)** es la alternativa recomendada a HDFS:

- **HDFS (On-Premise)**

- Almacenamiento **acoplado** al clúster
- Requiere gestionar DataNodes activos
- Esquema: `hdfs://`
- Los datos desaparecen si el clúster se elimina
- Escalado manual de capacidad

- **GCS (Cloud-Native)**

- Almacenamiento **desacoplado** del clúster
- Fully managed por Google
- Esquema: `gs://`
- Los datos ****persisten**** aunque el clúster sea eliminado
- Escalado automático e ilimitado

Referencias

Apache Software Foundation. (n.d.a). *HDFS architecture guide*. https://hadoop.apache.org/docs/r1.2.1/hdfs_design.html

Apache Software Foundation. (n.d.b). *HDFS commands guide* (Version 3.3.5). <https://hadoop.apache.org/docs/stable/hadoop-project-dist/hadoop-hdfs/HDFSCommands.html>

Apache Software Foundation. (n.d.c). *MapReduce tutorial*. <https://hadoop.apache.org/docs/stable/hadoop-mapreduce-client/hadoop-mapreduce-client-core/MapReduceTutorial.html>

Apache Software Foundation. (n.d.d). *Hadoop streaming*. <https://hadoop.apache.org/docs/current/hadoop-streaming/HadoopStreaming.html>

CodeWithFaraz. (n.d.). *Top 15 Hadoop ecosystem components in 2024: A comprehensive guide*. <https://www.codewithfaraz.com/article/78/top-15-hadoop-ecosystem-components-in-2024-a-comprehensive-guide>

DataFlair. (n.d.). *Hadoop ecosystem components*. <https://data-flair.training/blogs/hadoop-ecosystem-components/>

Databricks. (n.d.). *Hadoop ecosystem*. <https://www.databricks.com/glossary/hadoop-ecosystem>

Edureka. (n.d.). *Hadoop ecosystem*. <https://www.edureka.co/blog/hadoop-ecosystem>

freeCodeCamp. (n.d.). *What is Google Dataproc?*. <https://www.freecodecamp.org/news/what-is-google-dataproc/>

GeeksforGeeks. (n.d.). *Hadoop ecosystem*. <https://www.geeksforgeeks.org/dbms/hadoop-ecosystem/>

Google Cloud. (n.d.a). *Dataproc Hadoop data storage*. <https://docs.cloud.google.com/dataproc/docs/concepts/dataproc-hdfs>

Google Cloud. (n.d.b). *Use Cloud Client Libraries for Python*. <https://docs.cloud.google.com/dataproc/docs/tutorials/python-library-example>

LabEx. (n.d.a). *How to use HDFS commands to interact with Hadoop Distributed File System*. <https://labex.io/tutorials/hadoop-how-to-use-hdfs-commands-to-interact-with-hadoop-distributed-file-system-417618>

LabEx. (n.d.b). *How to configure HDFS in a Hadoop cluster*. <https://labex.io/tutorials/hadoop-how-to-configure-hdfs-in-a-hadoop-cluster-415124>

Wikipedia. (n.d.). *Apache Hadoop*. https://en.wikipedia.org/wiki/Apache_Hadoop